

LAPORAN HASIL *PROJECT* ANALISIS REGRESI LANJUTAN

Regresi Bayesian

Bagaimana Regresi Bayesian dapat digunakan untuk Memodelkan Hambatan Sisa (Residuary Resistance) Kapal secara tepat, terukur, dan dapat dijelaskan

Pengaruh Angka Kecepatan *Froude* terhadap Hambatan Sisa (*Residuary Resistance*) Kapal *Yacht* dengan Pengendalian Geometri Kapal melalui Pendekatan Regresi Bayesian



Disusun Oleh:

1. Hennyda Laura Br Tarigan (140720260015)
2. Yiska Friscilla (140720260014)

JURUSAN STATISTIKA TERAPAN

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

UNIVERSITAS PADJADJARAN

2026

1. Pendahuluan

Hambatan sisa (*residuary resistance*) merupakan komponen hambatan kapal yang bergantung pada geometri bentuk lambung kapal dan kecepatan angka *froude*. Prediksi yang akurat pada tahap awal perancangan geometri bentuk lambung dan penentuan kecepatan angka *froude* yang tepat maka akan memberikan hambatan sisa (*residuary resistance*) yang mempengaruhi pergerakan kapal tersebut dan membantu perancang menilai kinerja suatu desain geometri kapal sebelum dilakukan pengujian fisik. Tantangan utama pada data ini adalah distribusi variabel target yang tidak simetris, hubungan yang *non linier* antara variabel target dengan variabel prediktor utama angka kecepatan *froude* (fn), serta jumlah *desain* geometri lambung kapal yang sangat terbatas. Kondisi tersebut membuat regresi linear klasik pada skala asli kurang memadai dan membuka ruang bagi pendekatan yang secara eksplisit mengukur ketidakpastian melalui regresi bayesian.

2. Pengenalan Data dan Variabel

Analisis menggunakan 308 jumlah observasi data, terdapat 22 desain geometri lambung kapal dengan 14 tingkat kecepatan angka *froude* di setiap 22 desain geometri lambung kapal. Terdiri dari 6 variabel prediktor dan 1 variabel target, definisi dan deskripsi variabel sebagai berikut:

Variabel	Peran	Keterangan
LCB	Prediktor	Posisi longitudinal pusat apung (<i>longitudinal position of the center of buoyancy</i>)
PC	Prediktor	Koefisien prismatik (<i>prismatic coefficient</i>)
LDR	Prediktor	Rasio panjang-perpindahan (<i>length-displacement ratio</i>)
BDR	Prediktor	Rasio lebar-sarat (<i>beam-draught ratio</i>)
LBR	Prediktor	Rasio panjang-lebar (<i>length-beam ratio</i>)
Fn	Prediktor	Bilangan Froude (ukuran kecepatan tak berdimensi)
r	Target	Hambatan sisa (<i>residuary resistance</i>)

3. Rumusan Masalah dan Tujuan

Penelitian ini menjawab pertanyaan dari “Bagaimana regresi bayesian dengan penanganan transformasi pada variabel target (*residuary resistace*) dan pola polinomial kecepatan angka *froude* (fn) dengan derajat 2, dapat digunakan untuk memodelkan hambatan sisa (*residuary resistace*) kapal secara tepat, gterukur dan dapat dijelaskan. Dari hal tersebut maka dijabarkan tiga fokus adalah sebagai berikut:


1. Apakah transformasi variabel target (*residuary resistance*) dapat menstabilkan varians dan meluruskan hubungan dengan variabel prediktor?
2. Apakah model regresi bayesian menghasilkan estimasi yang stabil, terdiagnosis dengan baik, dan tidak sensitif terhadap pilihan *prior*?
3. Bagaimana hasil perbandingan prediksi regresi bayesian terhadap OLS (*baseline*) dan *ransom forest* (*benchmark*)

4. Eksplorasi Data dan Analisis

Pemeriksaan dari 308 jumlah observasi didapatkan hasil dimensi data adalah terdiri dari 308 baris dan 7 kolom yang yaitu 6 variabel prediktor dan 1 variabel terget, tidak terdapat *missing value*, tipe data adalah numerik, dan diperoleh hasil statistik deskriptif adalah sebagai berikut:

Variabel	Mean	SD	Median	Min	Max	Skew	Kurtosis
LCB	-2,38	1,51	-2,30	-5,00	0,00	-0,23	-0,26
PC	0,56	0,02	0,56	0,53	0,60	-0,04	-0,88
LDR	4,79	0,25	4,78	4,34	5,14	-0,43	-0,58
BDR	3,94	0,55	3,96	2,81	5,35	0,24	1,12
LBR	3,21	0,25	3,15	2,73	3,64	-0,19	-0,45
Fn	0,29	0,10	0,29	0,12	0,45	0,00	-1,22
r	10,49	15,16	3,06	0,01	62,42	1,74	1,97


Variabel target (r) memiliki kemiringan bernilai positif yaitu sebesar 1.74 dan terlihat dari nilai mean sebesar 10.49 jauh lebih besar dari nilai median 3.06, distribusi data variabel target (r) tidak simetris dan memiliki ekor (tail) yang lebih panjang ke sisi kanan (*right-skewed*). Variabel prediktor (fn) memiliki kemiringan 0 dengan nilai mean sebesar 0.29 dan nilai kurtosis -1.22 terdistribusi merata dengan nilai fn tersebar cukup luas (0.10-0.45) dan bentuknya relatif mendatar. Variabel prediktor (LCB, PC, LDR, BDR, LBR) secara umum relatif terdistribusi simetris terlihat nyata dari hasil histogram dan nilai *sweakness* mendekati 0, dengan nilai standar deviasi paling kecil terdapat pada variabel prediktor (PC) yaitu 0.02. Kemudian dilakukan pengecekan *outlier* melalui visualisasi *box-plot* didapatkan hasil sebagai berikut:



Dari hasil visualisasi yang memiliki *outlier* adalah pada variabel target (r), variabel prediktor (LCB dan BDR). Pada uji multikolinearitas didapatkan variabel yang memiliki multi dengan nilai $VIF > 10$ adalah variabel LDR sebesar 49.140343, BDR sebesar 35.034277, dan LBR sebesar 47.428023. Pada uji heteroskedastisitas didapatkan $p - value (1.007e - 12) < \alpha(0.05)$ artinya terdapat heteroskedastisitas pada residual data.

4.1 Transformasi Variabel Target (r)

Dilakukan transformasi logaritma pada variabel target (r) untuk menangani kemiringan diperoleh visualisasi distribusi dari variabel target r dan setelah dilakukan transformasi dengan log r adalah sebagai berikut:




----- Distribusi variabel target r dengan nilai *skewness* sebesar 1.739

----- Distribusi variabel target r setelah di transformasi menjadi $\log(r)$ dengan nilai *skewness* sebesar 0.466

Pada variabel target r ada kemiringan panjang ke sisi kanan (*right-skewed*) setelah dilakukan transformasi $\log(r)$ dapat menstabilkan *variance* data

4.2 Polinomial Variabel Prediktor (fn)

Dilakukan penanganan pola polynomial variabel prediktor (fn) menjadi derajat 2 (kuadratik) sehingga didapatkan visualisasi plot hubungan variabel target (r) terhadap variabel prediktor (fn), hubungan variabel target $\log(r)$ terhadap variabel prediktor (fn) dan hubungan variabel target $\log(r)$ terhadap variabel prediktor (f_n^2) sebagai berikut:



- (1) Plot variabel target (r) terhadap (fn), bersifat *non-linier* sangat curam dan pola data polinomial dimana sebaran titik r semakin melebar secara signifikan seiring bertambahnya nilai fn. Nilai korelasi sebesar 0.81
- (2) Plot variabel target (r) sudah ditransformasi menjadi $\log(r)$ terhadap (fn), bersifat *non-linier* dengan pola polinomial bertahap yang jauh lebih stabil. Nilai korelasi sebesar 0.982
- (3) Plot variabel target $\log(r)$ terhadap (f_n^2), bersifat *linier* dengan pola polinomial yang semakin stabil. Nilai korelasi sebesar 0.997

Dari hasil plot hubungan variabel target $\log(r)$ terhadap variabel prediktor (fn) masih menunjukkan *non-linier* sehingga penggunaan polinomial berderajat 2 akan dilakukan untuk menangkap hubungan yang *linier*.

4.3 Korelasi Variabel Prediktor terhadap Target

Hubungan variabel prediktor (LCB, PC, LDR, BDR, LBR) terhadap variabel target (r) memiliki korelasi yang rendah dan dengan transformasi $\log(r)$ pun tetap terlihat bahwa korelasi rendah, yang dapat dilihat dari nilai korelasi yang mendekati 0 menunjukkan tidak ada hubungan linier. Namun variabel prediktor tersebut akan tetap dipertahankan untuk melihat efek geometri kapal yang akan dipasangkan dengan variabel prediktor kecepatan angka *founder* (f_n^2).

4.4 Standarisasi dan Split Data

Standarisasi untuk 5 variabel prediktor (LCB, PC, LDR, BDR, LBR) agar koefisien sebanding dengan nilai variabel prediktor (f_n^2) dan variabel target $\log(r)$. Kemudian dilakukan *split* data dengan perbandingan 80:20 untuk dipakai dalam uji *train* dan *test* dalam pemodelan dan evaluasi model. Hasil *split* data adalah *train* sebanyak 246 (data ke-1 sampai 246) dan *test* sebanyak 62 data (data ke-247 sampai 308).

4.5 Pemodelan Regresi Bayesian


Dilakukan pemodelan regresi bayesian data *train* dari 5 variabel prediktor geometri kapal (LCB, PC, LDR, BDR, LBR) yang sudah distandarisasi, variabel prediktor kecepatan angka *founder* pola polinomial dengan derajat 2 kuadratik menjadi (f_n^2), dan variabel target (r) yang sudah ditransformasi logaritma menjadi $\log(r)$.

Dalam pemodelan regresi bayesian dilakukan pemilihan *likelihood*, *prior* yang akan menghasilkan *posterior*, dengan pemilihannya adalah sebagai berikut:

Likelihood (Gaussian Normal), **Prior weakly informative** dengan susunan **prior b (normal)** – **prior intercept (normal)** – **prior sigma (exponential)**, sehingga didapatkan model sebagai berikut:


$$\log(r) = \beta_0 + \beta_1 P_1(Fn_i) + \beta_2 P_2(Fn_i) + \beta_3 LCB_i + \beta_4 PC_i + \beta_5 LDR_i + \beta_6 BDR_i + \beta_7 LBR_i + \varepsilon_i, \varepsilon_i \sim N(0, \sigma^2)$$

Visualisasi plot distribusi *intercept*, polinomial f_n , polinomial f_n^2 , LCB, PC, LDR, BDR, LBR, *sigma* sebagai berikut:



4.6 Diagnostik dengan MCMC (Markov Chain Monte Carlo)

Dari hasil pemodelan regresi bayesian data *train* dan dilakukan diagnostik MCMC diperoleh **R-hat maksimum target** sebesar 1.0008 dan visualisasi MCMC model regresi bayesian untuk *intercept* dan polinomial f_n^2 serta residualnya adalah sebagai berikut:



4.7 Sensitivity Analisis Prior


Pada cek *sensitivity prior* dilakukan tiga spesifikasi untuk setiap parameter pada angka kecepatan *founder linier* (f_n) dan *founder kuadratik* (f_n^2) yaitu Normal (0, 0.5) sempit, Normal (0, 2.5) utama, dan Normal (0, 10) lebar. Hasil dari *sensitivity* analisis *prior* adalah sebagai berikut:

Pola Polinomial	Sensitivity	Prior	Estimate	Est.Error	Q2.5	Q97.5
polyFn21...1	Normal(0, 0.5)	Sempit	4.0210510	0.58162509	2.880088	5.170295
polyFn22...2	Normal(0, 0.5)	Sempit	0.7560408	0.44986568	-0.140767	1.628000
polyFn21...3	Normal(0, 2.5)	Utama	18.3435580	0.08388894	18.178550	18.506279
polyFn22...4	Normal(0, 2.5)	Utama	3.4118698	0.08282491	3.249447	3.575586
polyFn21...5	Normal(0, 10)	Lebar	18.3623071	0.08333504	18.195852	18.522906
polyFn22...6	Normal(0, 10)	Lebar	3.4163657	0.08379566	3.252687	3.579853

Dari hasil dapat dilihat bahwa Normal (0, 0.5) sempit menekan nilai estimasi dari 4.0210510 menjadi 0.7560408 yang dapat memberikan efek terlalu membatasi parameter, Normal (0, 2.5) utama dan Normal (0, 10) lebar memiliki nilai *standart error* yang kecil dengan hasil estimasi antara utama dan lebar hampir identik yang artinya memiliki *sensitivity* yang stabil dan konsisten. Sehingga, Normal (0, 2.5) utama adalah baik dan bersifat robust untuk dijadikan pilihan *Prior* yang akan digunakan.

4.8 Baseline Ordinary Least Squares (OLS)

Model OLS digunakan sebagai *baseline* untuk membandingkan performa antara nilai koefisien dan *standart error*. Diperoleh nilai R^2 sebesar 0.9954 artinya variabel prediktor mampu menjelaskan 99.54% variasi pada variabel target. Pola plot residual terstandarisasi mendekati garis lurus, dengan nilai *cook's D* melihat data *outlier* berjarak tinggi sehingga cukup mempengaruhi estimasi parameter, dan terjadi multikolinearitas nilai VIF > 10 pada variabel prediktor LDR sebesar 49.354479, BDR sebesar 34.980395, dan LBR sebesar 47.261522. Berikut ditampilkan plot residual model OLS dan *cook's distance* model OLS:



4.9 Benchmark Random Forest

Dilakukan *benchmark random forest* untuk mengetahui batas untuk prediksi pada data tanpa terkendala asumsi-asumsi klasik. Penggunaan *random forest* berbasis pohon keputusan sebagai pembanding untuk mengevaluasi model performa prediksi data. *Random forest* mampu menangkap hubungan *non-linear* dan interaksi kompleks antar variabel serta tidak sensitif terhadap masalah multikolinearitas yang sebelumnya pada OLS ditemukan adanya multikolinearitas. Diperoleh hasil *random forest* dengan *ntree* sebanyak 500 dan keakuratan tingkat kesalahan model dievaluasi menggunakan OOB (*out-of-bag*) sebesar 92.26%.

4.10 Evaluasi Model Regresi Bayesian, OLS, dan *Random Forest Data Test*

Validasi dilakukan pada 62 observasi data *test* yang tidak dipakai saat uji *train* (latih). Prediksi model untuk variabel target $\log(r)$ dikembalikan ke skala data asli. Sehingga diperoleh performa pada data uji dari ketiga model adalah sebagai berikut:


Model	RMSE	MAE	MAPE (%)	R^2
OLS (<i>baseline</i>)	1.730	0.8677	26.99	0.9888
Regresi Bayesian	1.725	0.8751	27.31	0.9889
Random Forest (<i>benchmark</i>)	4.384	2.8463	743.74	0.9282

Perbandingan regresi bayesian dengan OLS (*baseline*) menghasilkan nilai RMSE terkecil yaitu 1.725 dan R^2 terbesar yaitu 0.9889. Ini menunjukkan bahwa penentuan *prior* pada regresi bayesian berhasil memberikan sedikit peningkatan kestabilan prediksi varians keseluruhan dibandingkan dengan OLS sebagai *baseline*. Perbandingan regresi bayesian dengan *random forest (benchmark)* menghasilkan *error* yang jauh lebih rendah pada regresi bayesian yang artinya mampu mengatasi keterbatasan *random forest* pada *trend* data. Sehingga dapat disimpulkan bahwa regresi bayesian memiliki tingkat akurasi RMSE dan R^2 terbaik, mengatasi keterbatasan *trend* data dan inferensi statistik yang lebih unggul.


4.11 Cross Validation Parameter Model Regresi Bayesian

Dilakukan *cross validation* pada model regresi bayesian dengan *pareto smoothed importance sampling leave-one-out* (PSIS-Loo CV). Nilai *expected log predictive density* sebesar 13.2 bernilai positif dan tinggi menandakan kemampuan prediksi *out of sample* yang baik. Nilai *Leave-one-out-information criterion* sebesar -518.2 bernilai negatif dan jauh dari nol menunjukkan fit model yang kuat. Aproksimasi LOO sangat stabil, tidak ada data *outlier* yang mempengaruhi *posterior* dan hasil evaluasi dipercaya sepenuhnya tanpa perlu melakukan *refitting* manual.

4.12 Visualisasi



Visualisasi data aktual dengan prediksi Data *test*



Visualisasi Regresi Bayesian: *Prior*, *Likelihood* dan *Posterior*

5 Kesimpulan dan Rekomendasi

Berdasarkan hasil analisis maka diperoleh kesimpulan sebagai berikut:

1. Transformasi logaritma pada variabel target menurunkan *skewness* dari 1.739 menjadi 0.466, sehingga varians data menjadi jauh lebih stabil. Dari sisi hubungan dengan prediktor utama, nilai korelasi meningkat bertahap variabel target (r) terhadap F_n hanya 0.81 (non-linier), $\log(r)$ terhadap F_n naik menjadi 0.982, dan $\log(r)$ terhadap F_n^2 mencapai 0.997 (hampir linier sempurna). Ini membuktikan kombinasi transformasi log pada respons dan polinomial derajat dua pada F_n berhasil meluruskan hubungan yang semula sangat non-linier.
2. Diagnostik MCMC menunjukkan R -hat maksimum sebesar 1.0008 (sangat mendekati 1, menandakan konvergensi keempat rantai yang baik), didukung *trace plot* yang bercampur stasioner dan *QQ-plot* residual yang mendekati garis normal. Uji sensitivitas tiga skenario prior menunjukkan bahwa Normal (0, 2.5) dan Normal (0, 10) menghasilkan estimasi yang praktis identik (18.34 dengan 18.36), sementara hanya *prior* yang terlalu sempit Normal (0, 0.5) yang menekan estimasi secara berlebihan (turun menjadi 4.02). Ini membuktikan model *robust* terhadap pilihan *prior* selama *prior* tidak dibuat terlalu ketat, sehingga Normal (0, 2.5) dapat dipertanggungjawabkan sebagai pilihan akhir.
3. Pada 62 data uji, Regresi Bayesian memberikan performa terbaik di antara ketiga model (RMSE 1.725, R^2 0.9889), hanya berbeda sedikit dengan OLS sebagai *baseline* (RMSE 1.730, R^2 0.9888), dan jauh memiliki perbedaan jauh dengan *Random Forest* sebagai *benchmark* (RMSE 4.384, R^2 0.9282; MAPE hingga 743.74%). Keunggulan Regresi Bayesian atas OLS bukan hanya pada akurasi titik yang sedikit lebih baik, tetapi terutama pada kuantifikasi ketidakpastian melalui interval kredibel sesuatu yang tidak dimiliki OLS maupun *Random Forest*.

Daftar Pustaka

- Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2013). *Bayesian data analysis* (3rd ed.). CRC Press.
- Gerritsma, J., Onnink, R., & Versluis, A. (1981). Geometry, resistance and stability of the Delft systematic yacht hull series. *International Shipbuilding Progress*, 28(328), 276–297. <https://doi.org/10.3233/ISP-1981-2832801>
- Tew, S. Y., Boley, M., & Schmidt, D. F. (2023). Bayes beats cross validation: Fast and accurate ridge regression via expectation maximization. *Advances in Neural Information Processing Systems*, 36.