LAPORAN HASIL *PROJECT* ANALISIS REGRESI LANJUTAN

Regresi Bayesian

Bagaimana Regresi Bayesian dapat digunakan untuk Memodelkan Hambatan Sisa (*Residuary Resistance*) Kapal secara tepat, terukur, dan dapat dijelaskan

Pengaruh Angka Kecepatan *Froude* terhadap Hambatan Sisa (*Residuary Resistance*) Kapal *Yacht* dengan Pengendalian Geometri Kapal melalui Pendekatan Regresi Bayesian



Disusun Oleh:

1. Hennyda Laura Br Tarigan (140720260015)
2. Yiska Friscilla (140720260014)

PROGRAM STUDI S2 STATISTIKA TERAPAN
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS PADJADJARAN

2026

1. Pendahuluan

Hambatan sisa (*residuary resistance*) merupakan komponen hambatan kapal yang bergantung pada geometri bentuk lambung dan angka kecepatan *Froude*. Prediksi yang akurat pada tahap awal perancangan membantu perancang menilai kinerja suatu desain lambung kapal sebelum dilakukan pengujian fisik yang mahal. Tantangan utama pada data ini ada empat. Pertama, distribusi variabel target tidak simetris dan memiliki ekor panjang ke kanan. Kedua, hubungan antara target dan angka *Froude* (Fn) bersifat *non-linier*. Ketiga, sebaran residual melebar seiring naiknya Fn (heteroskedastisitas), disertai multikolinearitas yang sangat tinggi antar-variabel geometri lambung. Keempat, jumlah desain lambung yang diuji sangat terbatas. Kondisi tersebut membuat regresi linear klasik (OLS) kurang memadai dan membuka ruang bagi regresi Bayesian, yang dapat memodelkan bentuk hubungan, sebaran galat, dan ketidakpastian secara eksplisit.

2. Pengenalan Data dan Variabel

Analisis menggunakan 308 observasi yang berasal dari 22 desain geometri lambung kapal *yacht*, masing-masing diuji pada 14 tingkat angka *Froude* (0,125 sampai 0,450 dengan selang 0,025). Data terdiri dari 6 variabel prediktor dan 1 variabel target, dengan definisi sebagai berikut:

Tabel 1. Definisi variabel penelitian

Variabel	Peran	Keterangan
LCB	Prediktor	Posisi longitudinal pusat apung (*longitudinal position of the center of buoyancy*)
PC	Prediktor	Koefisien prismatik (*prismatic coefficient*)
LDR	Prediktor	Rasio panjang-perpindahan (*length-displacement ratio*)
BDR	Prediktor	Rasio lebar-sarat (*beam-draught ratio*)
LBR	Prediktor	Rasio panjang-lebar (*length-beam ratio*)
Fn	Prediktor	Bilangan *Froude* (ukuran kecepatan tak berdimensi)
r	Target	Hambatan sisa (*residuary resistance*)

3. Rumusan Masalah dan Tujuan

Penelitian ini menjawab pertanyaan: “Bagaimana regresi Bayesian, dengan penanganan hubungan *non-linier* Fn melalui *spline*, galat berekor berat (Student-*t*), ragam yang bergantung pada Fn, dan efek acak antar-desain lambung, dapat digunakan untuk memodelkan hambatan sisa (*residuary resistance*) kapal secara tepat, terukur, dan dapat dijelaskan?” Pertanyaan tersebut dijabarkan menjadi tiga fokus berikut:

1. Apakah spesifikasi model Bayesian (*spline* Fn, Student-*t*, *sigma* heteroskedastis, dan efek acak desain lambung) mampu menangani *non-linieritas*, *outlier*, heteroskedastisitas, dan multikolinearitas yang ditemukan pada data?
2. Apakah model regresi Bayesian menghasilkan estimasi yang stabil, terdiagnosis dengan baik, dan tidak sensitif terhadap pilihan *prior*?
3. Bagaimana perbandingan prediksi regresi Bayesian terhadap OLS (*baseline*) dan *random forest* (*benchmark*) pada data uji?

4. Eksplorasi Data dan Analisis

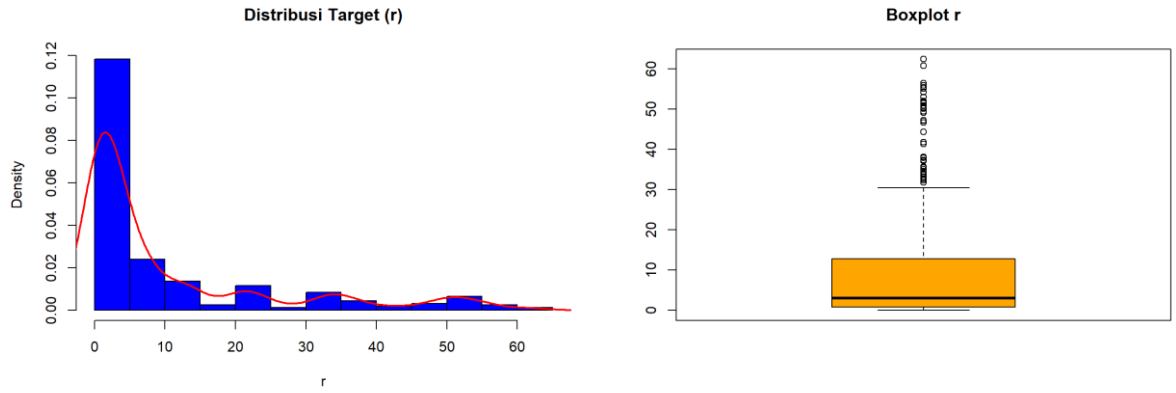
4.1 Pemeriksaan Awal dan Statistik Deskriptif

Data berdimensi 308 baris dan 7 kolom (6 prediktor dan 1 target). Seluruh variabel bertipe numerik dan tidak terdapat *missing value*. Statistik deskriptif disajikan pada tabel berikut:

Tabel 2. Statistik deskriptif variabel penelitian

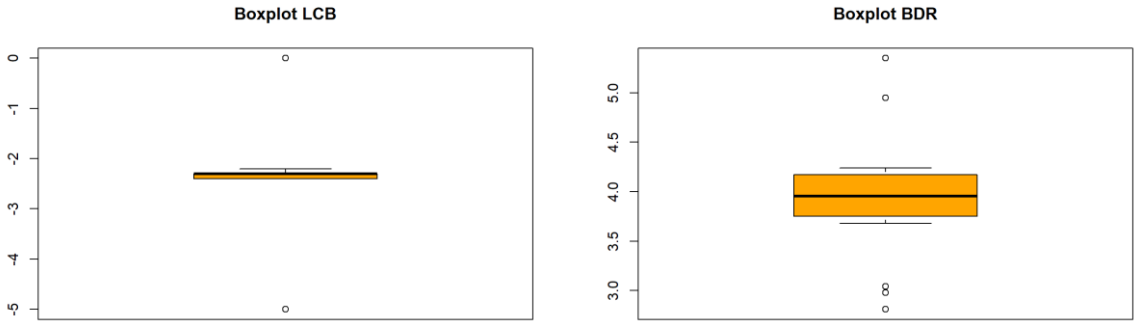
Variabel	Mean	SD	Median	Min	Max	Skew	Kurtosis
LCB	-2,38	1,51	-2,30	-5,00	0,00	-0,23	-0,26
PC	0,56	0,02	0,56	0,53	0,60	-0,04	-0,88
LDR	4,79	0,25	4,78	4,34	5,14	-0,43	-0,58
BDR	3,94	0,55	3,96	2,81	5,35	0,24	1,12
LBR	3,21	0,25	3,15	2,73	3,64	-0,19	-0,45
Fn	0,29	0,10	0,29	0,12	0,45	0,00	-1,22
r	10,49	15,16	3,06	0,01	62,42	1,74	1,97

Variabel target (r) memiliki kemiringan positif sebesar 1,74, dan nilai *mean* (10,49) jauh lebih besar daripada median (3,06). Distribusinya tidak simetris dengan ekor panjang ke kanan (*right-skewed*). Variabel Fn memiliki kemiringan 0 dan kurtosis -1,22, yaitu tersebar merata pada rentang 0,125 sampai 0,45 dengan bentuk relatif mendatar, karena setiap tingkat Fn muncul tepat 22 kali. Variabel geometri (LCB, PC, LDR, BDR, LBR) berkemiringan mendekati 0. Variabel PC memiliki simpangan baku terkecil, yaitu 0,02.



Gambar 1. Histogram variabel target (r) dan boxplot *variabel target (r)*

Pemeriksaan *outlier* dengan kriteria IQR menunjukkan bahwa variabel yang memiliki *outlier* adalah r (42 observasi), LCB (112 observasi), dan BDR (70 observasi), sedangkan PC, LDR, LBR, dan Fn tidak memiliki *outlier*. Banyaknya *outlier* pada LCB terjadi karena sebagian besar desain memiliki LCB sekitar -2,3, sementara hanya sebagian kecil desain bernilai -5 atau 0.

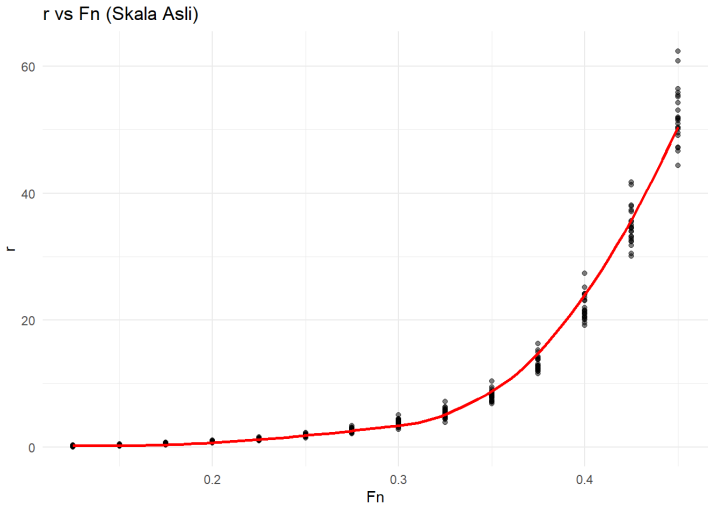


Gambar 2. Boxplot *variabel LCB dan BDR*

Uji multikolinearitas pada seluruh data memberikan nilai VIF > 10 pada LDR (49,14), BDR (35,03), dan LBR (47,43), sedangkan PC bernilai 4,05, LCB 1,00, dan Fn 1,00. Uji Breusch-Pagan menghasilkan BP = 68,091 dengan *p-value* $1{,}007\times10^{-12} < \alpha$ (0,05), yang berarti terdapat heteroskedastisitas pada residual.

4.2 Hubungan Variabel Prediktor terhadap Target

Korelasi Spearman variabel geometri terhadap r sangat rendah ($|\rho| \leq 0{,}018$), yang menunjukkan bahwa variabel geometri tidak berhubungan secara langsung dengan r. Sebaliknya, Fn memiliki korelasi Spearman 0,996 terhadap r, sedangkan korelasi Pearson hanya 0,81. Selisih ini menunjukkan hubungan yang sangat kuat tetapi *non-linier* (monoton naik secara melengkung). Pada plot, sebaran titik r juga semakin melebar seiring bertambahnya Fn, yang menjelaskan temuan heteroskedastisitas di atas.



Gambar 3. Plot r terhadap Fn pada skala asli dengan kurva loess

Variabel geometri tetap dipertahankan dalam model untuk melihat efeknya setelah pengaruh Fn dikendalikan. Antar-variabel geometri sendiri terdapat keterkaitan, misalnya LDR dengan LBR ($\rho = 0{,}665$) dan PC dengan BDR ($\rho = 0{,}453$), yang menjadi sumber multikolinearitas.

4.3 Standarisasi dan Pembagian Data

Seluruh variabel prediktor (LCB, PC, LDR, BDR, LBR, Fn) distandarisasi agar koefisien sebanding dan *prior* yang sama dapat diterapkan. Karena setiap desain lambung diuji pada 14 tingkat Fn, observasi dalam satu desain saling berkaitan. Pembagian data dilakukan per desain lambung (ID kapal) dengan perbandingan 80:20 agar tidak terjadi kebocoran data (*data leakage*). Hasilnya, data *train* terdiri dari 17 desain (238 observasi) dan data *test* terdiri dari 5 desain (70 observasi). Jumlah ID kapal yang beririsan antara *train* dan *test* adalah 0, sehingga tidak ada kebocoran data.

5. Pemodelan Regresi Bayesian

Berdasarkan diagnosis awal, setiap masalah data ditangani dengan komponen model Bayesian yang sesuai:

Tabel 3. Masalah data dan penanganan pada model Bayesian

Variabel	Permasalahan	Penanganan Bayesian
LCB	Terdapat *outlier*	Standardisasi + *regularizing prior*
PC	Tidak menunjukkan masalah	Standardisasi + *regularizing prior*
LDR	Multikolinearitas sangat tinggi	Standardisasi + *regularizing prior*
BDR	Terdapat *outlier* dan multikolinearitas tinggi	Standardisasi + *regularizing prior*
LBR	Multikolinearitas sangat tinggi	Standardisasi + *regularizing prior*
Fn	Hubungan terhadap r *non-linier*	*Spline* Bayesian s(Fn)
r	Skewness positif, *outlier*, dan heteroskedastisitas	Student-*t* + *sigma* ~ s(Fn)

Empat model Bayesian dibangun pada data *train* menggunakan paket *brms* (MCMC NUTS, 4 rantai, 4000 iterasi dengan 2000 *warmup*, total 8000 sampel posterior), semuanya dengan efek acak (1 | ID_kapal):

- Model Student-t*: efek linear untuk seluruh prediktor termasuk Fn, dengan* likelihood *Student*-t.
- Model Spline*: Fn dimodelkan dengan* spline *s(Fn),* likelihood *Student*-t*.
- Model Heteroskedastis: *spline* s(Fn) pada rata-rata dan pada parameter *sigma* (sigma ~ s(Fn)), *likelihood* Student-*t*.
- Model Skew-normal*: struktur sama dengan model heteroskedastis, tetapi dengan* likelihood skew-normal.

Prior yang digunakan bersifat *weakly informative*, yaitu koefisien (*b*) ~ Normal(0, 1), *intercept* ~ Student-*t*(3, 0, 10), simpangan baku efek acak (*sd*) dan *spline* (*sds*) ~ Exponential(1), derajat kebebasan *nu* ~ Gamma(2, 0,1), serta pada *sigma* digunakan *intercept* ~ Student-*t*(3, 0, 2,5) dan *sds* ~ Exponential(1). Perbandingan keempat model dilakukan dengan *leave-one-out cross validation* (LOO-CV) dan hasilnya sebagai berikut:

Tabel 4. Perbandingan model Bayesian berdasarkan LOO-CV

Model	elpd_diff	se_diff	Keterangan
Heteroskedastis (Student-*t* + *spline* + sigma ~ s(Fn))	**0,0**	**0,0**	**Terbaik**
Skew-normal	-0,6	1,0	Selisih < 4; 3 observasi pareto k > 0,7
Spline	-268,3	20,3	Jauh lebih buruk
Student-*t* (linear)	-670,4	19,9	Paling buruk

Model heteroskedastis menjadi yang terbaik. Dibanding model Student-*t* linear, peningkatan elpd mencapai 670,4, dan dibanding model *spline* tanpa *sigma* variabel peningkatannya 268,3, jauh melampaui galat bakunya (selisih ±20). Dengan demikian pemodelan hubungan *non-linier* dan ragam yang berubah menurut Fn sangat berpengaruh. Model *skew-normal* tidak dapat dibedakan secara nyata dari model heteroskedastis (selisih -0,6 dengan galat baku 1,0), parameter kemiringannya (*alpha* = -0,66; interval kredibel 95% dari -2,93 sampai 1,34) mencakup 0, serta menghasilkan 3 observasi dengan pareto k > 0,7. Oleh karena itu dipilih model yang lebih sederhana dan stabil, yaitu model heteroskedastis (Student-*t* + *spline* + heteroskedastisitas). Model akhir dapat dituliskan:

$$r_{ij} \sim \text{Student-t}(\nu, \mu_{ij}, \sigma_{ij})$$

$$\mu_{ij} = \beta_0 + \beta_1 \text{LCB}_{ij} + \beta_2 \text{PC}_{ij} + \beta_3 \text{LDR}_{ij} + \beta_4 \text{BDR}_{ij} + \beta_5 \text{LBR}_{ij} + f(\text{Fn}_{ij}) + u_j$$

$$u_j \sim N(0, \sigma_u^2)$$

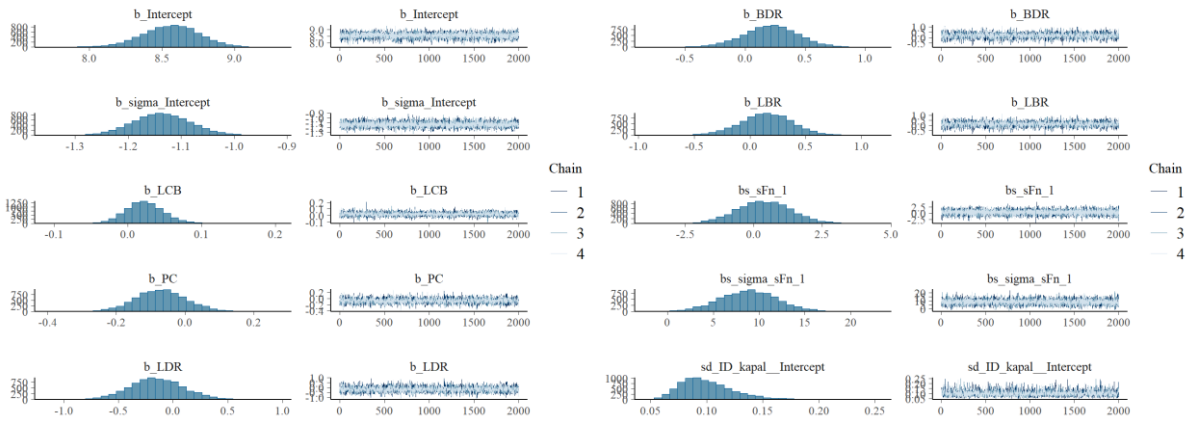
$$\log(\sigma_{ij}) = \gamma_0 + g(\text{Fn}_{ij})$$

dengan *i* adalah observasi (tingkat Fn), *j* adalah desain lambung, $f(\cdot)$ dan $g(\cdot)$ adalah fungsi *spline*, dan *u* adalah efek acak desain lambung. Ringkasan estimasi posterior model terpilih ditampilkan pada tabel berikut:

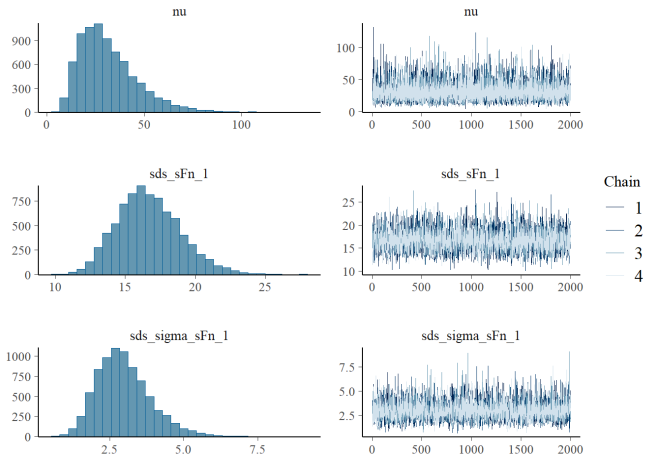
Tabel 5. Ringkasan estimasi posterior model terpilih

Parameter	Estimate	Est. Error	Q2,5	Q97,5
Intercept	8,56	0,20	8,15	8,93
LCB	0,02	0,03	-0,03	0,08
PC	-0,07	0,08	-0,22	0,08
LDR	-0,15	0,25	-0,64	0,36
BDR	0,21	0,23	-0,26	0,66
LBR	0,15	0,24	-0,33	0,61
sFn_1 (rata-rata)	0,36	0,99	-1,60	2,31
sigma_Intercept	-1,14	0,05	-1,24	-1,03
sigma_sFn_1	8,87	3,17	2,74	15,15
sd(Intercept) ID kapal	0,10	0,03	0,06	0,16
sds(sFn_1)	16,70	2,29	12,74	21,64
sds(sigma_sFn_1)	2,99	0,93	1,49	5,14
nu	31,70	15,06	11,24	68,67

Interval kredibel 95% seluruh koefisien geometri (LCB, PC, LDR, BDR, LBR) mencakup nol, sehingga setelah pengaruh Fn dikendalikan tidak ada bukti kuat adanya efek geometri lambung pada hambatan sisa. Pengaruh dominan datang dari Fn yang ditangkap oleh komponen *spline*. Meskipun LDR, BDR, dan LBR berkolinearitas tinggi, *prior* yang meregularisasi membuat simpangan baku posterior koefisiennya tetap wajar (0,23 sampai 0,25), sedangkan galat baku OLS pada variabel yang sama mencapai 6,12 sampai 6,72. Simpangan baku efek acak antar-desain kecil (0,10), artinya perbedaan antar-desain yang tersisa relatif kecil dibanding pengaruh Fn. Nilai $nu \approx 31{,}7$ menunjukkan bahwa setelah ragam dimodelkan menurut Fn, galat mendekati normal dan tidak lagi berekor sangat berat. Berbeda dengan model Student-*t* linear yang nilai *nu*-nya mendekati 1 untuk menutupi ketidaksesuaian struktur model. Distribusi posterior dan rantai MCMC parameter model disajikan berikut:



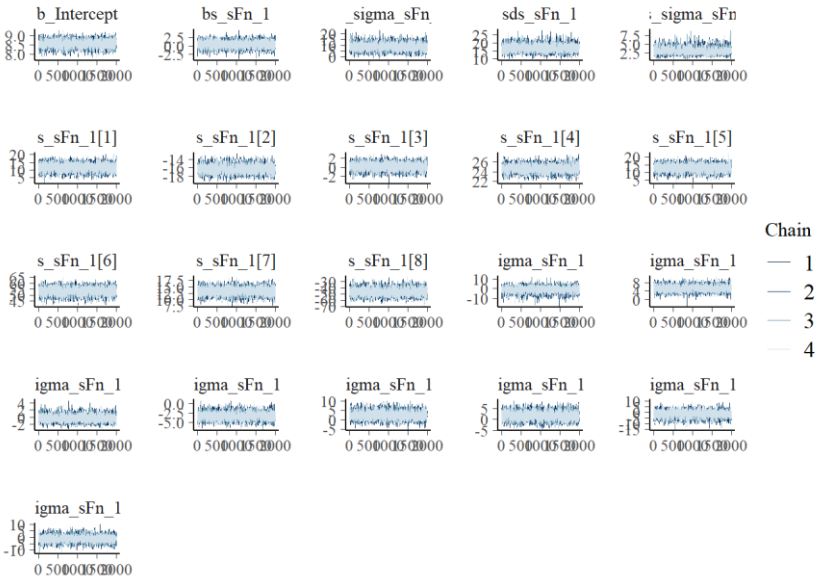
Gambar 4. Distribusi posterior dan trace plot *parameter model terpilih (bagian 1 dan 2)*



Gambar 5. Distribusi posterior dan trace plot *parameter model terpilih (bagian 3)*

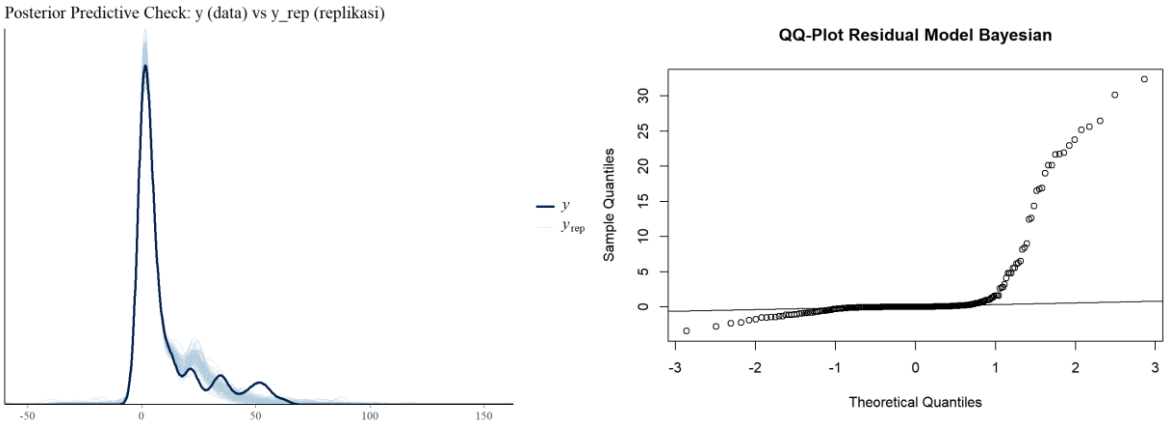
6. Diagnostik dengan MCMC (*Markov Chain Monte Carlo*)

Diagnostik MCMC pada model terpilih menghasilkan R-hat maksimum sebesar 1,0017 (target ≤ 1,01), sehingga keempat rantai dinyatakan konvergen. Seluruh parameter pada ringkasan model memiliki R-hat 1,00 dengan *effective sample size* (Bulk-ESS dan Tail-ESS) berkisar dari 2.653 sampai 12.939, yang cukup besar untuk estimasi yang andal. *Trace plot* menunjukkan rantai yang saling bercampur dan stasioner.



Gambar 6. Trace plot *MCMC parameter* spline *(rata-rata dan* sigma*) pada model terpilih*

Posterior predictive check menunjukkan bahwa distribusi replikasi (*y_rep*) mengikuti bentuk umum data aktual (*y*), yaitu massa terbesar di nilai r kecil dengan ekor ke kanan. Namun, replikasi masih lebih lebar dibanding data aktual dan menjangkau nilai negatif. *QQ-plot* residual Bayesian menunjukkan titik mengikuti garis di bagian tengah, tetapi menyimpang pada ekor kanan. Hal ini sejalan dengan kenyataan bahwa pada Fn yang tinggi galat model masih relatif besar.



Gambar 7. Posterior predictive check *dan* QQ-plot *residual model Bayesian*

7. Melakukan *Sensitivity* Analisis Prior

Uji sensitivitas dilakukan dengan menyesuaikan kembali model terpilih menggunakan tiga spesifikasi *prior* untuk koefisien (*b*), yaitu Normal(0, 0,5) kuat, Normal(0, 1) medium (*prior* utama), dan Normal(0, 2) lemah. Ketiganya dibandingkan dengan LOO-CV:

Tabel 6. Hasil sensitivitas prior *berdasarkan LOO-CV*

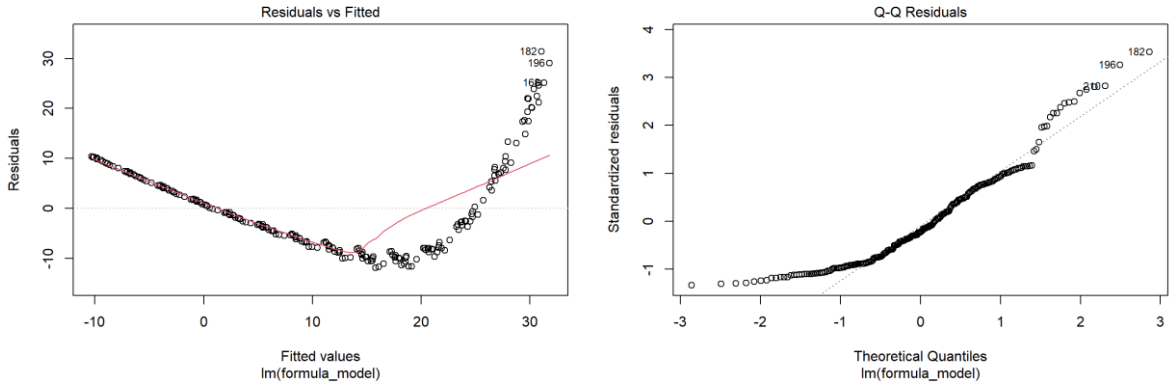
Spesifikasi *prior*	Kategori	elpd_diff	se_diff
Normal(0, 1)	Medium (utama)	0,0	0,0
Normal(0, 0,5)	Kuat	-0,1	0,2
Normal(0, 2)	Lemah	-0,4	0,2

Selisih elpd antar-spesifikasi sangat kecil (maksimum 0,4, dengan galat baku 0,2) dan seluruhnya di bawah ambang 4, yang berarti kemampuan prediksi ketiga model praktis setara. Dengan demikian, hasil model tidak sensitif terhadap pilihan kekuatan *prior* pada rentang yang diuji, sehingga Normal(0, 1) dapat dipertanggungjawabkan sebagai *prior* akhir. Sebagai catatan, perbandingan ini menandai adanya observasi dengan nilai pareto k > 0,7 (2 observasi pada salah satu model), sehingga hasil LOO dipakai dengan sedikit kehati-hatian.

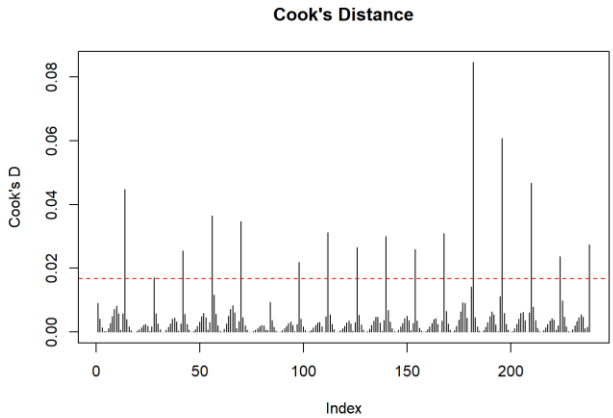
8. *Baseline Ordinary Least Squares* (OLS)

Model OLS, r ~ Fn + LCB + PC + LDR + BDR + LBR, dibangun pada data *train* sebagai *baseline*. Diperoleh R^2 sebesar 0,6547 (R^2 *adjusted* 0,6458), artinya prediktor hanya menjelaskan sekitar 65,5% variasi r. Hanya *intercept* (10,40) dan Fn (12,31) yang signifikan ($p < 2\times10^{-16}$), sedangkan seluruh variabel geometri tidak signifikan (p antara 0,60 dan 0,99) dengan galat baku yang sangat besar pada LDR (6,72), BDR (6,12), dan LBR (6,32).

Asumsi OLS banyak yang dilanggar. Multikolinearitas sangat tinggi pada data *train* dengan VIF LDR sebesar 155,40, LBR 115,28, BDR 87,96, dan PC 9,84. Uji Breusch-Pagan menghasilkan *p-value* $1{,}184\times10^{-9}$ (heteroskedastisitas), *skewness* residual sebesar 1,0098, dan plot *residuals vs fitted* menunjukkan pola melengkung yang berarti hubungan *non-linier* tidak tertangkap. Analisis *Cook's distance* menunjukkan 16 dari 238 observasi berpengaruh (di atas batas 4/n = 0,0168). Hasil ini sejalan dengan alasan digunakannya regresi Bayesian.



Gambar 8. Residuals vs fitted *dan* Q-Q residuals *model OLS*



Gambar 9. Cook's distance *model OLS*

9. *Benchmark Random Forest*

Random forest dengan 500 pohon (*ntree* = 500) digunakan sebagai *benchmark* untuk mengetahui batas kemampuan prediksi tanpa terikat asumsi klasik. Model berbasis pohon keputusan ini mampu menangkap hubungan *non-linier* dan interaksi kompleks, serta tidak sensitif terhadap multikolinearitas. Pada data *train*, model menjelaskan 91,63% variasi target berdasarkan evaluasi OOB (*out-of-bag*). Kelemahannya, *random forest* tidak memberikan interval ketidakpastian dan tidak dapat diinterpretasikan melalui koefisien.

10. Evaluasi Model Regresi Bayesian, OLS, dan *Random Forest*

Validasi dilakukan pada 70 observasi data *test* (5 desain lambung yang tidak dipakai saat pelatihan). Prediksi Bayesian dihitung dari rata-rata posterior (*posterior_epred*) dengan desain baru dianggap sebagai tingkat acak baru. Performa ketiga model pada data uji adalah sebagai berikut:

Tabel 7. Performa model pada data test *(n = 70)*

Model	RMSE	MAE	MAPE (%)	sMAPE (%)	R^2
OLS (*baseline*)	8,586	6,916	1559,51	100,14	0,6659
Regresi Bayesian	**5,918**	**2,299**	**27,51**	**20,16**	**0,8413**
Random Forest (*benchmark*)	3,228	2,208	472,18	60,86	0,9528

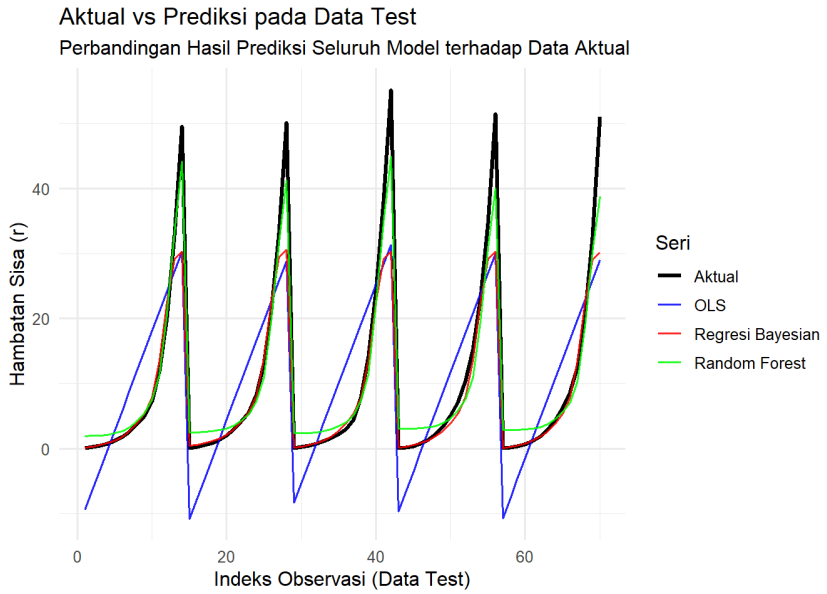
Catatan: nilai minimum r adalah 0,01 sehingga MAPE sangat sensitif terhadap nilai r yang kecil. Karena itu sMAPE, RMSE, dan MAE digunakan sebagai pelengkap.

Dibandingkan OLS (*baseline*), regresi Bayesian jauh lebih baik pada seluruh ukuran: RMSE turun dari 8,586 menjadi 5,918, MAE dari 6,916 menjadi 2,299, dan R^2 naik dari 0,6659 menjadi 0,8413. Prediksi OLS bahkan bernilai negatif pada r yang kecil (hambatan negatif tidak masuk akal), sedangkan prediksi Bayesian tetap berada di sekitar nol. Dibandingkan *random forest* (*benchmark*), regresi Bayesian unggul pada MAPE (27,51% vs 472,18%) dan sMAPE (20,16% vs 60,86%), yang berarti galat relatifnya jauh lebih kecil, terutama pada r kecil. Namun *random forest* masih lebih baik pada RMSE (3,228 vs 5,918) dan R^2 (0,9528 vs 0,8413), sedangkan MAE kedua model berdekatan (2,208 vs 2,299). Grafik aktual terhadap prediksi menunjukkan penyebabnya, yaitu prediksi Bayesian mendatar di sekitar 30 pada nilai aktual r di atas 30, sehingga galat besar terkonsentrasi pada Fn tinggi yang berada di luar jangkauan pola yang dipelajari dari data *train*.

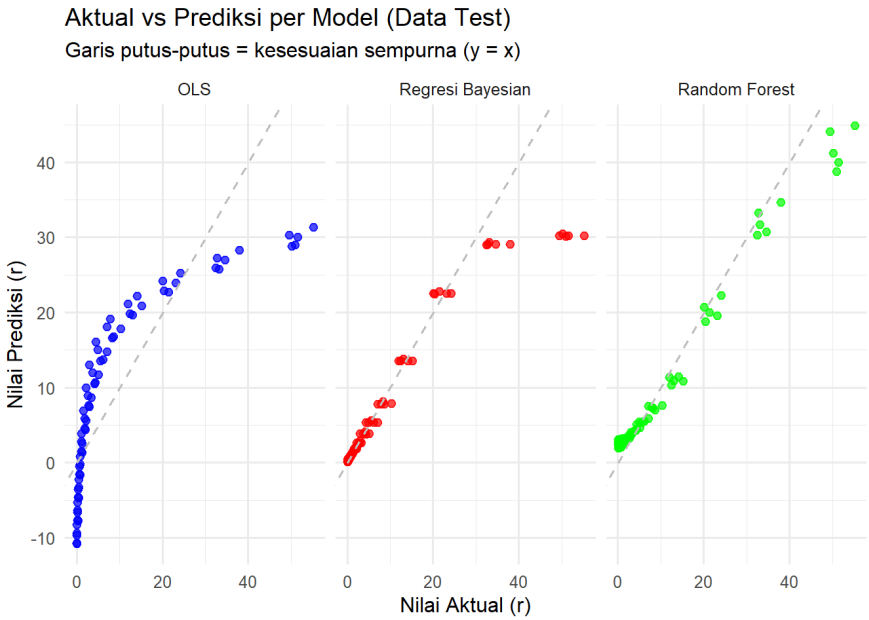
Keunggulan utama regresi Bayesian terletak pada kuantifikasi ketidakpastian. Interval prediksi 95% model Bayesian pada data *test* memiliki cakupan (*coverage*) sebesar 94,3%, sangat dekat dengan nilai nominal 95%, sehingga ketidakpastian prediksi terkalibrasi dengan baik. Hal ini tidak dimiliki OLS (dengan asumsi ragam konstan yang dilanggar) maupun *random forest*.

11. Visualisasi

Berikut adalah hasil visualisasi dari data aktual dengan prediksi seluruh model (OLS, Regresi bayesian, dan *Random forest) pada* data *test*:



Gambar 10. Aktual vs prediksi seluruh model pada data test *berdasarkan indeks observasi*



Gambar 11. Aktual vs prediksi per model pada data test *(garis putus-putus: kesesuaian sempurna y = x)*

Pola pada Gambar 10 muncul karena setiap desain lambung diuji pada 14 tingkat Fn yang berurutan. Garis Bayesian (merah) mengikuti kenaikan r dengan baik sampai tingkat Fn menengah dan tertahan pada puncak yang tinggi, sedangkan garis OLS (biru) menyimpang jauh dan *random forest* (hijau) paling mendekati puncak.

5. Kesimpulan dan Rekomendasi

Berdasarkan hasil analisis diperoleh kesimpulan sebagai berikut:

1. Data memiliki distribusi target yang miring ke kanan (*skewness* 1,74), hubungan Fn dengan r yang kuat tetapi *non-linier* (Spearman 0,996), heteroskedastisitas (BP $p = 1{,}007\times10^{-12}$), serta multikolinearitas sangat tinggi pada LDR, BDR, dan LBR (VIF 35 sampai 49). Model Bayesian yang menggabungkan *spline* Fn, *likelihood* Student-*t*, *sigma* yang bergantung pada Fn, dan efek acak desain lambung menangani seluruh masalah tersebut. Dalam LOO-CV, model ini unggul jauh atas model Student-*t* linear (elpd lebih baik 670,4) dan model *spline* tanpa heteroskedastisitas (elpd lebih baik 268,3), serta setara dengan model *skew-normal* yang lebih rumit.
2. Diagnostik MCMC menunjukkan R-hat maksimum 1,0017 (konvergen) dengan *effective sample size* yang besar dan *trace plot* yang stasioner. Uji sensitivitas tiga *prior* (Normal(0, 0,5), Normal(0, 1), Normal(0, 2)) menghasilkan selisih elpd maksimum hanya 0,4 (jauh di bawah ambang 4), sehingga model tidak sensitif terhadap pilihan *prior*. *Prior* yang meregularisasi juga menstabilkan koefisien geometri yang berkolinearitas tinggi, dengan simpangan baku posterior ±0,25 dibanding galat baku OLS ±6. Seluruh koefisien geometri tidak berbeda nyata dari nol setelah Fn dikendalikan, sehingga Fn merupakan penentu utama hambatan sisa.
3. Pada 70 data uji, regresi Bayesian jauh lebih baik daripada OLS (RMSE 5,918 vs 8,586; R^2 0,8413 vs 0,6659) dan memiliki galat relatif terkecil (MAPE 27,51%; sMAPE 20,16%). *Random forest* tetap yang terbaik pada RMSE dan R^2 (3,228 dan 0,9528) karena regresi Bayesian cenderung menaksir terlalu rendah pada r di atas 30. Keunggulan regresi Bayesian terletak pada interval prediksi 95% yang terkalibrasi baik (cakupan 94,3%) dan parameter yang dapat ditafsirkan, hal yang tidak dimiliki OLS maupun *random forest*.

Rekomendasi untuk pengembangan selanjutnya:

- Menambah jumlah desain lambung dan cakupan nilai Fn pada data latih, karena hanya 17 desain yang dipakai untuk pelatihan dan 5 desain untuk pengujian, sehingga prediksi pada Fn tinggi masih kurang andal.
- Menggunakan MAPE dengan hati-hati karena r bernilai sangat kecil (minimum 0,01), dengan menjadikan sMAPE, RMSE, dan MAE sebagai ukuran pendamping.

Daftar Pustaka

Bürkner, P.-C. (2017). brms: An R package for Bayesian multilevel models using Stan. *Journal of Statistical Software, 80*(1), 1–28. https://doi.org/10.18637/jss.v080.i01

Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2013). *Bayesian data analysis* (3rd ed.). CRC Press.

Gerritsma, J., Onnink, R., & Versluis, A. (1981). Geometry, resistance and stability of the Delft systematic yacht hull series. *International Shipbuilding Progress, 28*(328), 276–297. https://doi.org/10.3233/ISP-1981-2832801

Tew, S. Y., Boley, M., & Schmidt, D. F. (2023). Bayes beats cross validation: Fast and accurate ridge regression via expectation maximization. *Advances in Neural Information Processing Systems, 36*.

Vehtari, A., Gelman, A., & Gabry, J. (2017). Practical Bayesian model evaluation using leave-one-out cross-validation and WAIC. *Statistics and Computing, 27*(5), 1413–1432. https://doi.org/10.1007/s11222-016-9696-4